

Guide de Reentrainement des Modeles CNN

APPIN

Auteur : Julien Guibert - INRAe Toxalim / MetaboHUB
Version 1.1 - Mars 2026

Table des matieres

1. Vue d'ensemble
2. Structure des dossiers
3. Format des annotations
4. Entrainement TOCSY/COSY
5. Entrainement HSQC
6. Verification et deploiement
7. Resolution de problemes

1. Vue d'ensemble

APPIN utilise deux modeles CNN distincts pour la detection de pics :

Modele	Types de spectres	Caracteristiques	Fichier weights
CNN 1H	TOCSY, COSY, UFCOSY	F1 et F2 en 1H (0-14 ppm)	saved_model/weights
CNN HSQC	HSQC	F1 en 1H, F2 en 13C (0-200 ppm)	saved_model/weights_hsqc

Principe d'entrainement

Les deux modeles suivent la meme approche :

1. Decomposition 2D -> 1D : Les spectres 2D sont decoupees en coupes 1D
2. Generation synthetique : Des spectres 1D artificiels enrichissent le dataset
3. Entrainement supervise : Classification des points + regression (position, intensite, largeur)

2. Structure des dossiers

```
CNN_Training/
spectres_reels/
  TOCSY/
    sample_001/pdata/1/
    sample_002/pdata/1/
  COSY/
  HSQC/
    hsqc_001/pdata/1/
    hsqc_002/pdata/1/
annotations/
  TOCSY_sample_001_peaks.csv
  COSY_xxx_peaks.csv
  HSQC_hsqc_001_peaks.csv
reference_data/
  BddReference_CPMG_2025-08-28.Rdata # Pour spectres 1H
  BddReference_C13_2025-08-28.Rdata # Pour spectres 13C
scripts/
  CNN_learn.R           # Script TOCSY/COSY
  CNN_train_HSQC.R      # Script HSQC
  spectrum_generator_random.R # Generateur synthetique
saved_model/
  weights/              # Modele TOCSY/COSY
  weights_hsqc/         # Modele HSQC
```

3. Format des annotations

Chaque spectre reel doit avoir un fichier CSV d'annotations correspondant.

Format CSV

F1_ppm,F2_ppm,intensity
3.45,2.15,1.0
4.12,3.89,0.8
1.23,1.23,0.6

Colonne	Description	Obligatoire
F1_ppm	Position du pic en F1 (ppm)	Oui
F2_ppm	Position du pic en F2 (ppm)	Oui
intensity	Intensite relative (0-1)	Non (default: 1.0)

Conventions de nommage

Dossier spectre	Fichier annotation
spectres_reels/TOCSY/sample_001/	annotations/TOCSY_sample_001_peaks.csv
spectres_reels/HSQC/hsqc_001/	annotations/HSQC_hsqc_001_peaks.csv

4. Entrainement TOCSY/COSY

4.1 Prerequis

```
# Packages necessaires
library(keras)
library(tensorflow)
library(dplyr)
library(purrr)
library(abind)

# Charger les scripts
source("scripts/CNN_learn.R")
source("scripts/spectrum_generator_random.R")

# Charger les bases de metabolites
load("reference_data/BdDReference_CPMG_2025-08-28.Rdata")
```

4.2 Execution avec fine-tuning

NOUVEAU : Le script CNN_learn.R supporte maintenant l'option use_pretrained pour choisir entre fine-tuning et entrainement from scratch.

```
# === SCRIPT COMPLET TOCSY/COSY ===
setwd("C:/Users/xxx/Documents/CNN_Training")

# 1. Charger les dependances
source("scripts/CNN_learn.R")
source("scripts/spectrum_generator_random.R")
load("reference_data/BdDReference_CPMG_2025-08-28.Rdata")

# 2. Scanner les spectres
spectres <- scan_spectres_folder(
  base_dir = "spectres_reels",
  annotations_dir = "annotations"
)

# 3. Filtrer TOCSY/COSY uniquement
spectres_1H <- spectres[sapply(spectres, function(x)
  x$type %in% c("TOCSY", "COSY", "UFCOSY"))]

# 4. Configurer le fine-tuning
use_pretrained <- TRUE # FALSE pour repartir de zero

# 5. Entrainer
result <- train_tocsy_cosy_model(
  spectres_info = spectres_1H,
  n_synthetic = 5000,
  epochs = 200,
  save_path = "saved_model/weights_v2"
)
```

5. Entraînement HSQC

L'HSQC nécessite un modèle séparé car $F1 = {}^1\text{H}$ (0-14 ppm) mais $F2 = {}^{13}\text{C}$ (0-200 ppm), les largeurs de raies ${}^{13}\text{C}$ sont différentes, et les patterns de pics sont différents.

5.1 Script dédié

Le fichier `CNN_train_HSQC.R` contient tout le nécessaire avec l'option `use_pretrained` activée par défaut.

```
source("scripts/CNN_train_HSQC.R")

# Entraînement complet avec fine-tuning (par défaut)
train_hsqc_cnn()

# Sans fine-tuning (from scratch)
train_hsqc_cnn(use_pretrained = FALSE)

# Avec moins de spectres synthétiques
train_hsqc_cnn(n_synthetic_1H = 1000, n_synthetic_13C = 1000)
```

5.2 Fonctions clés du script HSQC

Fonction	Description
<code>build_peak_predictor()</code>	Construit l'architecture CNN
<code>generate_synthetic_1D_spectrum()</code>	Génère un spectre 1D synthétique
<code>generate_hsqc_training_dataset()</code>	Crée un dataset mixte ${}^1\text{H}$ + ${}^{13}\text{C}$
<code>extract_hsqc_cuts()</code>	Extrait les coupes 1D d'un spectre HSQC réel
<code>train_hsqc_cnn()</code>	Fonction principale avec <code>use_pretrained</code>

6. Verification et deployment

6.1 Verifier les modeles

```
check_cnn_models <- function() {  
  cat("\n=== Verification des modeles CNN ===\n\n")  
  models <- list(  
    "TOCSY/COSY" = "saved_model/weights",  
    "HSQC" = "saved_model/weights_hsqc"  
  )  
  for (name in names(models)) {  
    path <- models[[name]]  
    exists <- dir.exists(path) || file.exists(paste0(path, ".index"))  
    status <- if (exists) "OK" else "Manquant"  
    cat(sprintf("  %s: %s (%s)\n", name, status, path))  
  }  
}  
check_cnn_models()
```

6.2 Deployer dans APPIN

```
# Pour TOCSY/COSY  
file.copy(  
  from = "CNN_Training/saved_model/weights_v2",  
  to = "APPIN_1.0.0/saved_model/weights",  
  recursive = TRUE,  
  overwrite = TRUE  
)  
  
# Pour HSQC  
file.copy(  
  from = "CNN_Training/saved_model/weights_hsqc",  
  to = "APPIN_1.0.0/saved_model/weights_hsqc",  
  recursive = TRUE,  
  overwrite = TRUE  
)
```

7. Resolution de problemes

Erreurs courantes

Erreur	Cause	Solution
Error in read.csv: file not found	Fichier annotation manquant	Vérifier le nommage
Column F1_ppm not found	Mauvais format CSV	Vérifier les noms de colonnes
Out of memory	Dataset trop grand	Reduire batch_size a 16
Loss is NaN	Donnees mal normalisees	Vérifier la normalisation
Model weights not found	Chemin incorrect	Vérifier saved_model/weights

Parametres recommandes

Parametre	TOCSY/COSY	HSQC
n_synthetic	5000	2000 (1000 + 1000)
epochs	200	200
batch_size	32	32
validation_split	0.2	0.2
patience (early stop)	50	50
use_pretrained	TRUE (par default)	TRUE (par default)

Temps d'entrainement estimes

Configuration	Temps estime
CPU seul	3-6 heures
GPU NVIDIA	30-60 minutes
GPU + donnees reduites	15-30 minutes

Checklist TOCSY/COSY

- ☐ Créer la structure de dossiers
- ☐ Copier les spectres Bruker dans spectres_reels/TOCSY/ ou COSY/
- ☐ Créer les fichiers CSV d'annotations

- ☐ Copier les fichiers .Rdata de reference
- ☐ Configurer use_pretrained (TRUE pour fine-tuning)
- ☐ Executer l'entrainement
- ☐ Verifier avec check_cnn_models()
- ☐ Tester sur un spectre
- ☐ Deployer dans APPIN

Checklist HSQC

- ☐ Copier les spectres HSQC dans spectres_reels/HSQC/
- ☐ Creer les annotations CSV (F2 en ¹³C, 0-200 ppm)
- ☐ Configurer use_pretrained selon le besoin
- ☐ Executer train_hsqc_cnn()
- ☐ Verifier avec check_cnn_models()
- ☐ Deployer weights_hsqc dans APPIN

Guide de Reentrainement des Modeles CNN - v1.1
APPIN - INRAe Toxalim / MetaboHUB - Mars 2026